

# 星を基準とした点集合データによる星座識別手法の提案

## 1 はじめに

近年、機械学習の急速な発展を背景にして、人工知能 (Artificial Intelligence: AI) を用いた認識技術が注目を集めている。特に画像認識の分野においては盛んに研究成果が報告されており、ニューラルネットワークの登場によって広範なタスクにおいて高い精度での物体認識が可能となってきた。一方で、天体写真は対象の天体とそれ以外の領域の線引きが難しく、また撮影者や機材の違いによって写っている星の状態が大きく異なるため、天体写真から星座を認識するのは AI をもってしても非常に困難な課題となっている。加えて、AI の学習に必要なデータセットが不足していることも認識を難しくしている一因となっている。これらの問題に対し、これまでの研究ではデータセット拡充のために独自の星座画像を作成し、これを畳み込みニューラルネットワーク (Convolution Neural Network: CNN) [1] で学習させて星座を識別する手法を提案し、一定の有効性を確認することができている。この識別精度を向上させるため、本研究では星座を星という点の集合として捉えるという新たな視点のもとで星座を識別する手法を提案する。

## 2 要素技術

### 2.1 VGG

VGG [2] とは、2014 年に Oxford 大学の研究チームによって提案された CNN モデルの一つであり、13 層の畳み込み層と 3 層の全結合層の合計 16 層からなる VGG16 や、16 層の畳み込み層と 3 層の全結合層の合計 19 層からなる VGG19 などがある。2014 年の画像認識大会で好成績を収めたことからその後のモデルアーキテクチャに広く取り入れられている。また ImageNet と呼ばれる大規模画像データセットで学習済みのモデルが公開されており、このモデルを転移学習してほかの画像認識タスクに適用することの有効性が報告されている。

### 2.2 PointNet

PointNet [3] とは、2016 年にスウェーデン大学によって提案された点群分類、セグメント深層学習フ

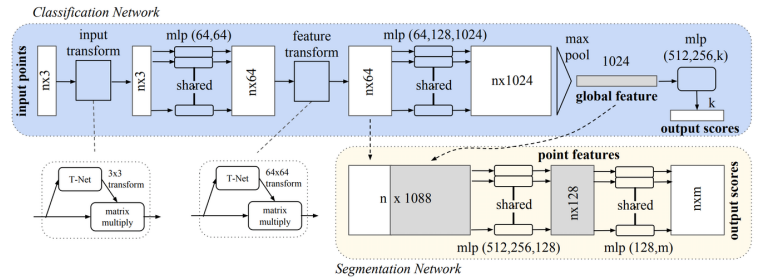


図 1: PointNet のアーキテクチャ

レームワークである。点群データとは、三次元の直交座標で表される点集合データであり、三次元物体を表現するのに適している。PointNet では、点群データにおける以下の二つの性質が考慮されている。

- 順不変性: 点の順序を入れ替えて入力しても出力が不変である。
- 移動不変性: 平行移動や回転移動をして入力しても出力が不変である。

図 1 に PointNet のアーキテクチャを示す。PointNet では、ネットワークの最終層に MaxPooling を用いることで順不変性を獲得している。またニューラルネットワークと MaxPooling の組み合わせからなる層 (T-Net) に入力点群を通して得られるアフィン行列と入力点群を行列乗算する Transform 層を入れることで近似的な移動不変性を実現している。これらの特性により、PointNet は点群データの分類問題とセグメンテーションにおいて高い精度を達成したことが報告されている。

## 3 実験

本研究では星座を星という点の集合として捉えるという視点のもとで、星の座標を用いて星座を識別する手法を提案し、画像認識で星座を識別する手法と比較することで提案手法の有効性を確認する。なお本研究で識別対象とした星座は、ふたご座、おおいぬ座、オリオン座、おうし座、さそり座の計 5 種類である。



図 2: オリオン座の星図

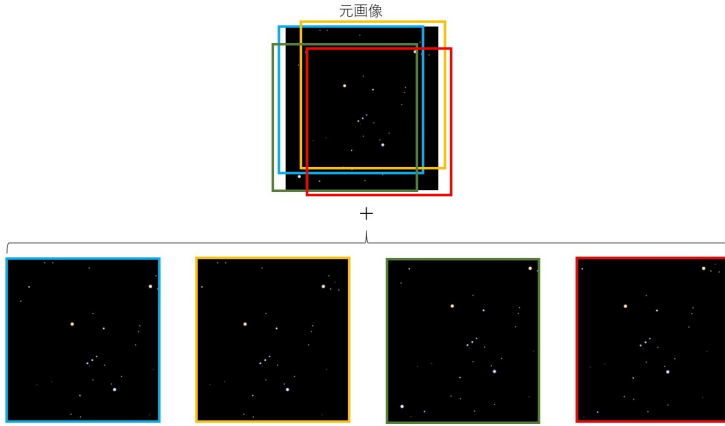


図 3: 星図の切り出し方

### 3.1 データセット

本研究で用いるデータセットは、欧州宇宙機関の位置天文衛星ヒッパルコスによる観測結果を元に編集、公開されているヒッパルコス星表のデータをもとに筆者が独自に作成した星座画像である。使用したのは視等級<sup>1</sup>が 4.0 未満の計 516 個の星の赤経<sup>2</sup>、赤緯<sup>2</sup>、視等級、スペクトル型<sup>3</sup>の情報である。赤経と赤緯の値から天球座標系における  $x$  座標,  $y$  座標,  $z$  座標を、スペクトル型から星の色を、視等級の値から星の直径の大きさをそれぞれ求め、これらの情報を統合して独自の天球を作成する。なおこのとき、投影天球の半径は 1000, 星の直径の大きさは  $15 / (\text{視等級})$  とした。次に作成した天球内に任意に二次元平面を定め、その平面上に星を投影する。なお平面の座標は、各星座に合わせて筆者が独自に決定したものであり、平面自体はすべてのピクセル値が 0 のものとする。最後に、星を投影した平面に対してガウシアンフィルタをかけることで星座画像の完成と

<sup>1</sup>肉眼または望遠鏡で見た天体の明るさから決めた等級

<sup>2</sup>天体の位置を表す値

<sup>3</sup>恒星が放つスペクトルによって分類されるもので色情報を含む

表 1: 実験パラメータ (CNN)

最適化関数	SGD
モーメントム	0.9
学習率	$1.0 \times 10^{-4}$
損失関数	categorical cross entropy
エポック数	100
画像サイズ	$256 \times 256$
バッチサイズ	6

する。以降、作成した星座画像を星図と呼ぶ。図 2 にオリオン座の星図を示す。

この方法を用いて、切り取る平面の大きさを変えて各星座につき 4 種類の星図を作成し、星座が大きく写っている写真から小さく写っている写真まで幅広く対応できるようにした。また各星図に関して図 3 に示すように星図を四分分割したものも追加で作成した。これにより星座が上下左右に平行移動したバージョンも学習できるようにした。これらに加えて、各星図につきそれぞれ  $-180^\circ \sim 150^\circ$  の範囲で  $30^\circ$  間隔で回転させた回転画像計 12 枚も作成した。以上より、各星座 (5 種類) につき 4 (切り取る平面の大きさの違い)  $\times$  5 (星図の分割)  $\times$  12 (回転画像) の 240 枚、合計 1200 枚の星図を作成した。

### 3.2 CNN による画像識別実験 (比較実験)

星座を星という点の集合として捉えるという視点のもとで星の座標を用いて識別実験をする前に、比較実験として CNN による画像認識で星座を識別する実験をした。なお本実験では学習器として VGG19 を用いた。訓練画像には作成した全星図 1200 枚を、テスト画像にはスクレイピングによって収集した各星座 3 枚ずつ、合計 15 枚の写真を使用した。表 1 に実験パラメータを示す。

#### 3.2.1 比較実験 1

本実験では、星図との類似性が小さくなることを考慮して、テスト画像にのみ画像の輝度に関して閾値を設け、それよりも小さな輝度をもつピクセルは黒塗りする処理を施した。初期重みには ImageNet で事前学習済みモデルを使用し、17 層目以降をファインチューニングした。

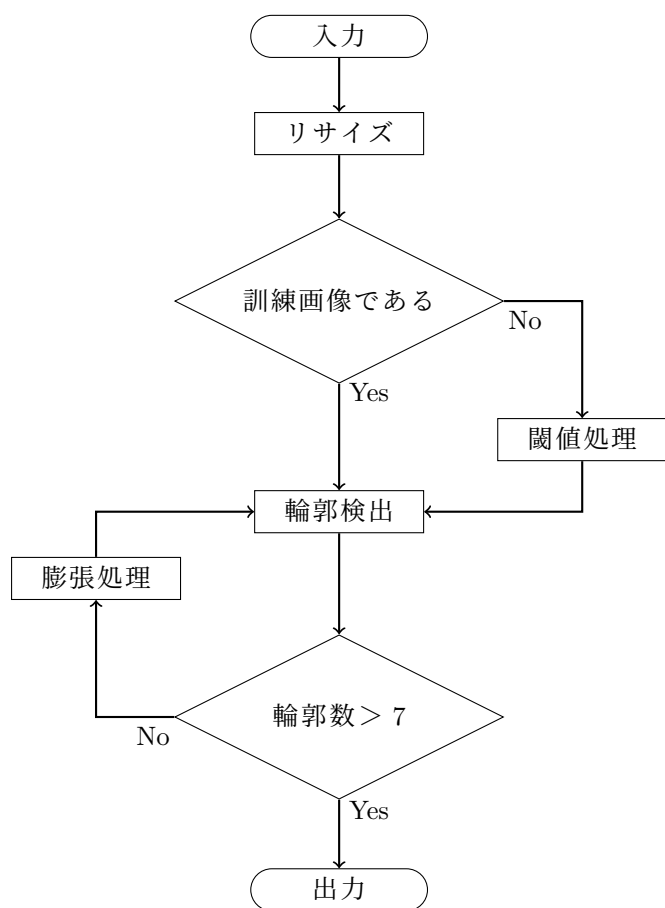


図 4: 輪郭抽出フローチャート

### 3.2.2 比較実験 2

本実験では訓練およびテスト画像に対して面積が上位 8 個の星のみを抽出した画像を作成して識別を試みた。まず図 4 に示すフローチャートに従って 8 個以上の輪郭 (星) の、画像における座標および面積のデータを獲得する。なおフローチャートに記した閾値処理は、比較実験 1 でテスト画像に施した閾値処理と同じ処理である。次に表 2 に示すようにしてこのデータを面積に対して降順に並べ替え、上位 8 個の星に関して、入力画像と同じサイズの黒色画像に描画する。なおこのとき、星はすべて同じ大きさで描画した。図 5 にオリオン座の描画例を示す。


### 3.2.3 比較実験 3

本実験では比較実験 2 と同様に星の輪郭を抽出し、黒色画像に面積が上位 8 個の星を描画するが、比較実験 2 と異なりこのとき各星の面積の関係性も考慮した。図 5 にオリオン座の描画例を示す。

表 2: オリオン座の輪郭データ

x 座標	y 座標	面積
82	69	78.0
181	222	72.0
119	162	51.5
129	153	38.0
155	78	34.5
231	118	33.5
139	145	26.5
100	237	25.5
130	43	22.0
130	200	21.5
⋮		
⋮		
⋮		

ここから上のデータを使用



比較実験 2



比較実験 3

図 5: 比較実験 2 および 3 の描画例

表 3 に各実験の 5 回試行におけるテスト画像の accuracy の平均と標準偏差、および各星座の平均識別枚数の結果を示す。面積が大きい星を抽出して識別した場合 (比較実験 2, 3) のほうがそうでない場合 (比較実験 1) と比べて accuracy が高くなっており、また多くの星座において平均識別枚数が多くなっていることがわかる。これにより面積が大きな星に着目して識別する手法の有効性が確認された。また星の輪郭を抽出してこれらを同じ大きさで描画した比較実験 2 が星の面積関係を考慮した比較実験 3 と比べて accuracy が高くなることもわかった。これは、天体写真に写る星の大きさの相対関係が実際の等級関係と異なっていることが多いため、全て同じ大きさで表現したほうが星図と写真との類似度が高くなり、accuracy が高くなったと考えられる。これにより、星図データセットを用いた星座の識別には星の面積関係よりも星同士の位置関係を重視したほうが accuracy が高くなるという考察が得られた。

表 3: 各実験におけるテスト画像の accuracy の平均と標準偏差, および各星座の平均識別枚数の結果

	accuracy		平均識別枚数				
	平均	標準偏差	ふたご座	おおいぬ座	オリオン座	おうし座	さそり座
比較実験 1	0.373	0.090	0	1.4	2.0	0.6	1.4
比較実験 2	0.640	0.033	2.0	2.2	2.8	2.0	0.6
比較実験 3	0.587	0.050	2.2	2.6	2.0	2.0	0
PointNet による識別実験	0.720	0.050	2.8	1.8	3.0	1.6	1.6

表 4: 実験パラメータ (PointNet)

最適化関数	Adam
学習率	$1.0 \times 10^{-4}$
エポック数	500
画像サイズ	$256 \times 256$
バッチサイズ	6

### 3.3 PointNet による識別実験

本実験では, 星座を星という点の集合として捉え, PointNet に星の座標を入力して識別実験をした. まず図 4 に示すフローチャートに従って 8 個以上の輪郭 (星) の, 画像における座標および面積のデータを獲得する. 次にこのデータを面積に対して降順に並べ替え, 上位 8 個の星の座標を PointNet の入力とする. なお本来, PointNet は三次元座標を入力するように設計されているが, 本実験では二次元座標を扱えるようにネットワークを構成し直している. また本実験では比較実験で得られた考察から, 星の座標のみを入力とし, 星の面積関係に関しては考慮していない. 表 4 に実験パラメータを示す. また本実験では (1), (2) 式で示す計算式を用いて損失関数  $L$  の算出をしている.

$$L = L_H + L_{\text{reg}}, \quad (1)$$

$$L_{\text{reg}} = \|I - AA^T\|_F^2. \quad (2)$$

ここで,  $L_H$  は cross entropy loss,  $A$  は T-Net で出力された特徴行列である. cross entropy loss に正則化項  $L_{\text{reg}}$  を追加することで最適化がより安定し, モデルの性能が向上することが報告されている.

表 3 に 5 回試行におけるテスト画像の accuracy の平均と標準偏差, および各星座の平均識別枚数の結果を示す. 本実験は面積が大きな星に着目し, か

つ星の位置関係のみを考慮する比較実験 2 と同じ条件下での実験であったが, 結果は比較実験 2 を上回るものとなった. このことから星座識別において星座を星の集合として捉え, 星の座標をもとに識別する手法の有効性を確認することができた.

## 4 まとめと今後の課題

本研究では星座を星という点の集合として捉えて星の座標をもとに識別する手法を提案し, 画像認識で星座を識別する手法と比較することで, PointNet を用いた提案手法の方が優れていることを確認することができた. また二種類の実験より星図データセットを用いる際に面積が大きな星に着目し, かつ星の面積関係よりも星同士の位置関係を重視する識別手法の有効性も確認することができた. なお本研究では 5 星座のみに対して識別を試みたため, 今後は識別星座数を増やしても同様の精度が得られるのかを確認していきたい. また PointNet をもとにした, 星座識別用のネットワークの構築も目指していきたいと考えている.

## 参考文献

- [1] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6):84–90, #jun# 2017.
- [2] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015.
- [3] Charles Ruizhongtai Qi, Hao Su, Kaichun Mo, and Leonidas J. Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. *CoRR*, abs/1612.00593, 2016.