

敵対的生成ネットワークを用いた天体画像生成

1 はじめに

近年、機械学習の急速な発展を背景にして、人工知能 (Artificial Intelligence: AI) による生成物が注目を集めている。特に画像分野においては、敵対的生成ネットワーク (Generative Adversarial Networks: GAN) [1] の登場により、さまざまな場面において高品質な画像編集や画像生成が可能となった。しかしながら天体写真においては、写っている星の並びが重要な要素の一つである一方で、各星の位置関係に関するデータセットが十分に存在せず星の並びを正確に生成するのは難しいため、AI による天体写真の編集、生成は非常に困難なタスクとなっている。

そこで本研究では、AI による天体写真の自動編集を最終目標とし、その前段階として天体写真風の画像 (以降、天体画像とする) の生成手法を提案する。具体的な手法としては、生成タスクを背景の生成と星座の生成の 2 段階にわけ、背景の生成に GAN を、星座の生成にこれまでに提案した星図の作成方法 [2] を用いることで本物の天体写真と類似した天体画像を生成する。

2 要素技術

2.1 敵対的生成ネットワーク

敵対的生成ネットワーク (Generative Adversarial Networks: GAN) [1] は 2014 年に Goodfellow らによって発表された教師なし学習の手法を用いた生成モデルの一種で、データから特徴を学習することで既存データの変換や未知データの生成をする。図 1 に GAN のアーキテクチャを示す。Generator と呼ばれる生成ネットワークと Discriminator と呼ばれる識別ネットワークの二つのネットワークから構成されており、これらを互いに競わせて学習させることで精度の高い画像の編集、生成を実現している。また GAN はいくつか応用研究が発表されており、その一つに各ネットワークに全結合層ではなく畳み込み層を使用した DCGAN (Deep Convolutional GAN) がある。DCGAN はネットワークを深くしたことで学習が安定し、オリジナルの GAN よりも自然な画像が生成されることが報告されている。

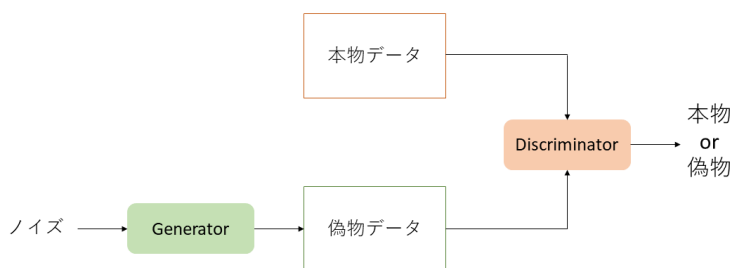


図 1: GAN のアーキテクチャ

2.2 VGGNet

VGG [3] とは、2014 年に Oxford 大学の研究チームによって発表された CNN モデルの一つであり、13 層の畳み込み層と 3 層の全結合層の合計 16 層からなる VGG16 や、16 層の畳み込み層と 3 層の全結合層の合計 19 層からなる VGG19 などがある。2014 年の画像認識大会で好成績を収めたことからその後のモデルアーキテクチャに広く取り入れられている。また ImageNet と呼ばれる大規模画像データセットで学習済みのモデルが公開されており、このモデルを転移学習してほかの画像認識タスクに適用することの有効性が報告されている。

2.3 Grad-CAM

Gradient-weighted Class Activation Mapping (Grad-CAM) [4] とは CNN の判断根拠の可視化技術であり、予測値に対する勾配を重み付けすることで CNN が分類のために注視している範囲をカラーマップで表示する。なお本研究の Grad-CAM の結果は注視レベルが最も高い領域が赤色で、続いて注視レベルが下がるごとに黄、緑、青色の順で色分けがなされるようにしている。

3 実験

本研究では本物の天体写真と類似した天体画像を生成する生成実験と、生成された天体画像の精度を評価するための識別実験をした。なお生成実験は背景の生成と星座の生成の 2 段階で構成されている。また識別実験では生成された天体画像がどれほど本



図 2: 背景の生成例

表 1: 実験パラメータ (DCGAN)

最適化関数	Adam
beta 1	0.5
beta 2	0.999
学習率	2.0×10^{-4}
ノイズの次元数	100
損失関数	binary cross entropy
エポック数	100
画像サイズ	128×128
バッチサイズ	16



星図

天体画像

図 3: 星図と天体画像の比較

物の天体写真に似ているかを定量的に評価するとともに、その結果を Grad-CAM に適用することで判断根拠を可視化し、より本物の天体写真に近づける方法を検討する。

3.1 生成実験

3.1.1 背景の生成

本実験では、天体画像の背景の生成に DCGAN を用いた。訓練データには、スクレイピングによって収集してきた 200 枚の天体写真に、回転や切り抜きなどの Data Augmentation を施して 12000 枚に拡張したものを使用した。表 1 に実験パラメータを示す。なお最適化関数, beta 1, beta 2, 学習率は Generator と Discriminator で共通のパラメータである。

図 2 に背景の生成例を示す。定性的な評価ではあるが、ある程度天体写真らしい背景が生成されているように感じられる。しかしながら訓練データに回転画像も使用していることから、不自然なところに黒い影が生成されてしまっている場合もあった

め、これにどう対応するかについては今後の課題である。

3.1.2 星座の生成

GAN では個々の星を明示的に生成できるわけではないので、既存の星座を生成できないという問題がある。そこで本実験では、星座の生成にこれまでに提案した星図の作成方法を利用して既存の星座を付加する手法を提案する。これまでの研究で、アメリカ航空宇宙局 (NASA) が公開しているヒッパルコス星表のデータを用いて地球から見た星の状態を天球上に再現し、天球上の星を平面に投影することで星図の作成に成功している。ここで、投影の際に背景として用いていたのはすべてのピクセル値が 0 の黒色画像であったが、本実験では 3.1.1 で生成された画像を背景として用い、これに星座を付加した。また本実験では星の描画の際に描画サイズの変更や星の大きさに応じた平滑化処理を施すことで、より天体写真らしくなったようにした。図 3 にオリオン座を例として、星図と本実験で生成した天体画像を示す。




図 4: 天体画像 (生成画像) と天体写真を並べた例 (配置はランダム)

表 2: 実験パラメータ (VGG19)

最適化関数	Adam
学習率	1.0×10^{-4}
損失関数	binary cross entropy
エポック数	100 (early stopping あり)
画像サイズ	128×128
バッチサイズ	6

また図 4 にこの手法を用いて生成した天体画像と本物の天体写真をランダムに並べた例を示す。こちらでも定性的な評価ではあるが、いずれの場合においても本物の天体写真と比べても遜色ない出来であるといえる。

3.2 識別実験

本実験では、3.1 で生成した天体画像が実際にどれほど本物の天体写真と類似しているかを定量的に評価するために、VGG19 を用いて天体画像と天体写真を識別することを試みた。訓練データには、3.1 の方法で生成した 100 枚の天体画像、およびスクレイピングによって収集してきた 100 枚の天体写真に、回転や切り抜きなどの Data Augmentation を施してそれぞれ 6000 枚、合計 12000 枚に拡張したものを使用した。なおこのうちの 1200 枚は検証用データとして用いた。またテスト画像には、3.1 の方法で生成した 10 枚の天体画像と大阪府立大学天文部より提供して頂いた 10 枚の天体写真を使用した。表 2 に実験パラメータを示す。初期重みには ImageNet で事前学習済みモデルを使用し、17 層目以降をファインチューニングした。


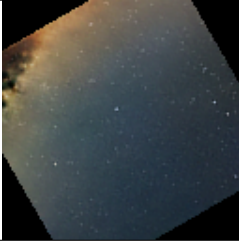
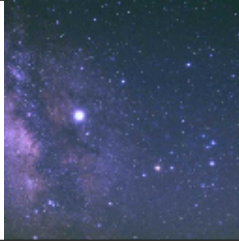
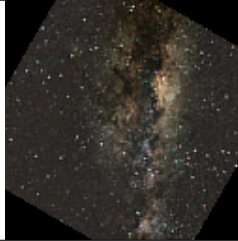
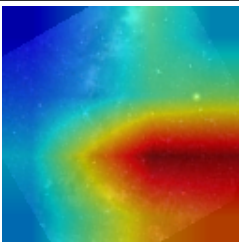
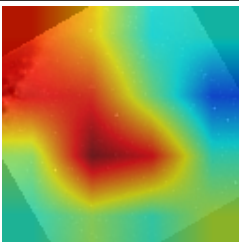
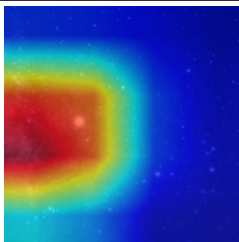
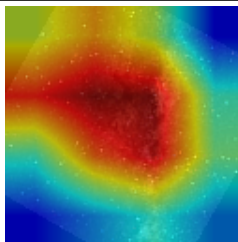
表 3: 識別結果

		予測値	
		天体画像 (生成画像)	天体写真
真 値	天体画像 (生成画像)	8	2
	天体写真	1	9

表 3 に結果の混同行列を示す。なお検証用データの loss が 5 epoch 改善されなかった場合に early stopping がかかるように設定していたため、訓練は 19 epoch 目で終了した。表 3 の結果より、天体画像と天体写真の識別精度が高いことから、人間の目ではうまく生成できているように見えても人工知能を騙せるほどの画像はまだ生成できていないことがわかる。

次に、天体画像と天体写真の違いがどこにあるのかを確かめるために、Grad-CAM を用いて CNN の注視領域を可視化した。表 4 に、天体画像および天体写真の Grad-CAM の適用結果を示す。左から順に、天体画像であると正しく識別された画像、天体画像であるが天体写真と識別された画像、天体写真であるが天体画像と識別された画像、天体写真であると正しく識別された画像である。この結果より、CNN は星雲や銀河により注目して判断していることがわかる。GAN によって生成された星雲や銀河は人間からすれば本物のように見えるが、CNN からすればそこには明確な違いが存在したためにこのような結果になったと考えられる。また、本研究では GAN の訓練に用いた元データ数が 200 枚と少なかったため同

表 4: Grad-CAM の適用結果

	天体画像 (生成画像)		天体写真	
元画像				
Grad-CAM				
識別結果	天体画像 (生成画像)	天体写真	天体画像 (生成画像)	天体写真

じような星雲や銀河が生成される確率が高かったことも識別に影響を与えたと考えられる。一方で、星雲や銀河が写っていない場合には天体画像が天体写真であると誤識別されていた例もあることから、星雲や銀河以外の要素に関してはうまく生成がなされていたと思われる。

またここで、星にはほとんど注視領域がかかっていないことから、CNN は背景画像のみを判断根拠としていることもわかる。一方で天体写真は写っている星自体も重要な要素であるため、CNN のみでは「天体写真らしさ」を測りきることはできないと考えられる。したがって今後は「天体写真らしさ」を測る新たな指標を導入する必要があると思われる。

4 まとめと今後の課題

本研究では本物の天体写真と類似した天体画像を生成するために、生成タスクを背景の生成と星座の生成の2段階にわけ、背景の生成に GAN を、星座の生成にこれまでに提案した星図の作成方法を用いる手法を提案し、人間の目では本物の天体写真と類似していると思われる天体画像の生成に成功した。一方で、まだ人工知能を騙せるほどの精度の高い画像は生成できていないため、今後は訓練データ数を増やすことでより多くの星雲や銀河の特徴を学習させることや、GAN を用いた画像復元手法を用いるなどして生成の際に不自然な影が生成されてしまうことに対応することで天体写真らしさを追及していき

たいと考えている。またこれらに加え、アンケート調査を取り入れるなどして「天体写真らしさ」を測る新たな指標の導入についても検討していきたいと考えている。より天体写真らしい天体画像が生成できるようになれば、AI による天体写真の自動編集や星空の自動生成にも繋がっていくと考えられる。

参考文献

- [1] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial networks, 2014.
- [2] 灘本 紗也佳, 森 直樹, and 岡田 真. 星図データに基づく星座画像の生成と星座識別手法の提案. 人工知能学会全国大会論文集, JSAI2021:3D1OS12a03–3D1OS12a03, 2021.
- [3] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition, 2015.
- [4] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336–359, Oct 2019.