

# 敵対的生成ネットワークを用いた星空画像生成手法の提案

## 1 はじめに

近年、機械学習の急速な発展を背景にして、人工知能 (Artificial Intelligence: AI) による創作物生成が注目を集めている。特に画像分野においては、敵対的生成ネットワーク (Generative Adversarial Networks: GAN) [1] の登場により、さまざまな領域において高品質な画像編集や画像生成が可能となった。しかしながら星空写真においては、写っている星の並びが重要な要素の一つである一方で、各星の位置関係に関するデータセットが十分には存在せず星の並びを正確に生成するのは難しいため、AI による星空写真の編集、生成は非常に困難なタスクとなっている。

そこで本研究では、AI による星空写真の自動編集を最終目標とし、その前段階として AI を用いて星空写真と類似した画像を生成する手法を提案する。

## 2 要素技術

### 2.1 敵対的生成ネットワーク

敵対的生成ネットワーク (Generative Adversarial Networks: GAN) [1] は 2014 年に Goodfellow らによって発表された教師なし学習の手法を用いた生成モデルの一種で、データから特徴を学習することで既存データの変換や未知データを生成する。

図 1 に GAN のアーキテクチャを示す。Generator と呼ばれる生成ネットワークと Discriminator と呼ばれる識別ネットワークの二つのネットワークから構成されており、これらを互いに競わせて学習させることで精度の高い画像の編集、生成を実現している。また GAN はいくつか応用研究が発表されており、その一つに各ネットワークに全結合層ではなく畳み込み層を使用した DCGAN (Deep Convolutional GAN) がある。DCGAN はネットワークを深くしたことで学習が安定し、オリジナルの GAN よりも自然な画像が生成されることが報告されている。本研究では画像生成の際に DCGAN を用いた。

### 2.2 VGGNet

VGG [2] は、2014 年に Oxford 大学の研究チームによって発表された CNN モデルの一つであり、13

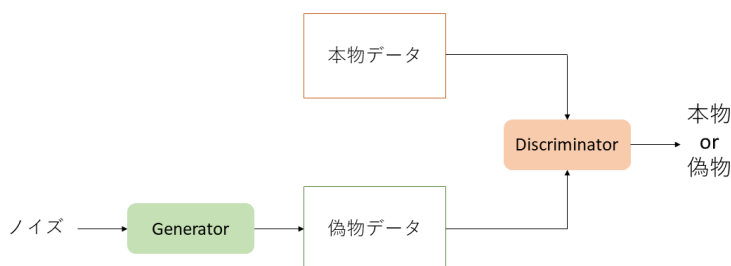


図 1: GAN のアーキテクチャ

層の畳み込み層と 3 層の全結合層の合計 16 層からなる VGG16 や、16 層の畳み込み層と 3 層の全結合層の合計 19 層からなる VGG19 などがある。2014 年の画像認識大会で好成績を収めたことからその後のモデルアーキテクチャに広く取り入れられている。また ImageNet と呼ばれる大規模画像データセットで学習済みのモデルが公開されており、このモデルを転移学習してほかの画像認識タスクに適用することの有効性が報告されている。本研究では生成画像の評価に VGG19 を用いた。

### 2.3 Grad-CAM

Gradient-weighted Class Activation Mapping (Grad-CAM) [3] は CNN の判断根拠の可視化技術であり、予測値に対する勾配を重み付けすることで CNN が分類のために注視している領域をカラーマップで表示する。なお本研究における Grad-CAM の結果は注視レベルが最も高い領域が赤色で、続いて注視レベルが下がるごとに黄、緑、青色の順であらわされるように定義した。

### 2.4 共分散行列適応進化戦略

共分散行列適応進化戦略 (Covariance Matrix Adaptation Evolution Strategy: CMA-ES) [4] は、共分散行列適応 (covariance matrix adaptation: CMA) と進化戦略 (evolution strategy: ES) を組み合わせた連続最適化問題のアルゴリズムである。多変量正規分布に基づいて解を生成し、解の評価値を用いて共分散行列を更新していくという手法で、変数間の依




図 2: 生成画像例

表 1: 実験パラメータ (DCGAN)

最適化関数	Adam
beta 1	0.5
beta 2	0.999
学習率	$2.0 \times 10^{-4}$
ノイズの次元数	100
損失関数	Binary Cross Entropy
エポック数	100
画像サイズ	$128 \times 128$
バッチサイズ	16

存関係がある問題や変数間のスケールが異なる問題に対して有効であることが報告されている. 本研究ではより星空写真と類似した画像の探索に CMA-ES を用いた.

### 3 提案手法

本研究では, GAN とこれまでに提案した星座画像の作成方法 [5] を用いることで星空写真と類似した画像を生成する手法を提案する. またその精度をアンケート調査および VGG19 を用いた識別実験で評価し, より星空写真と類似した画像の生成方法を検討する.

#### 3.1 星空画像の生成実験

本実験では, 星空画像の生成に DCGAN を用いた. 訓練データには, Web スクレイピングによって収集してきた 200 枚の星空写真に,  $30^\circ$  ごとの回転およ



図 3: 星座を付加する前後の画像例

び 5 分割の切り抜きの Data Augmentation を施して 12000 枚に拡張したものを使用した. 表 1 に実験パラメータを示す. なお Generator と Discriminator で共通のパラメータを用いた. 図 2 に生成画像例を示す. 定性的な評価ではあるが, ある程度星空写真と類似した画像が生成されているといえる.

一方で GAN では個々の星を明示的に生成できないため, 既存の星座を生成できないという問題がある. そこで本実験では, 星座の生成にこれまでに提案した星座画像の作成方法を利用して生成画像に既存の星座を付加する手法を提案する. これまでの研究で, アメリカ航空宇宙局が公開しているヒッパルコス星表のデータを用いて地球から見た星の状態を天球上に再現し, 天球上の星を平面に投影することで星図の作成に成功している. このとき星はすべてのピクセル値が 0 の黒色画像上に投影したが, 本実験では生成画像上に星を投影することで星座を付加した. なお本実験では星座の付加の際に星の大きさに応じた平滑化処理, 画像の明るさ調整や鮮鋭化処理を施すことで, より星空写真に類似した画像にな




図 4: 生成した星空画像と実際の星空写真を並べた例 (配置はランダム)

るようにした. ここで, どの範囲の星座をどの生成画像に付加するかは著者らが無作為に決定した. 図 3 に星座を付加する前後の画像例を示す. また図 4 にこの手法を用いて生成した星空画像と実際の星空写真をランダムに並べた例を示す. こちらも定性的な評価ではあるが, 星座を付加することで人間の目から見ても実際の星空写真と遜色ない質の画像が生成できたといえる.

## 3.2 評価実験

### 3.2.1 アンケート調査

本実験では 3.1 で生成した星空画像と実際の星空写真を人間が見分けることができるのかというアンケート調査をした. アンケート調査では, 図 4 に示すように生成した星空画像 9 枚と実際の星空写真 9 枚をランダムに並べた 18 枚の画像群の中から, 生成した星空画像であると思う画像を 9 枚選択してもらった. またこのとき実験協力者には自身の属性についても以下の 3 タイプから回答してもらった.

- 天体写真はほとんど見たことがないし, 天文に関する基礎知識ももっていない

- 自分で天体写真は撮らないが天体写真は見たことがある, または天文に関する基礎知識ももっている
- 自分でも天体写真を撮る

実験協力者は天文部の OB と OG, および所属研究室のメンバー計 29 人である. このうち「自分でも天体写真を撮る」人が最も少なく 4 人であり, 「天体写真はほとんど見たことがないし, 天文に関する基礎知識ももっていない」人と「自分で天体写真は撮らないが天体写真は見たことがある, または天文に関する基礎知識ももっている」人はほぼ同数でありそれぞれ 12 人と 13 人であった. 図 5 にアンケート結果を示す. なお横軸が正解数, 縦軸が人数である. 正解数が 0~2, および 9 の人は一人もいなかった. また天体写真をほとんど見たことがない人は比較的正解数が低く, 自分でも天体写真を撮る人は比較的正解数が高くなる傾向にあった.

各属性における平均正答率は, 「天体写真はほとんど見たことがないし, 天文に関する基礎知識ももっていない」人が 0.49, 「自分で天体写真は撮らないが天体写真は見たことがある, または天文に関する基礎知識ももっている」人が 0.58, 「自分でも天体写真を撮る」人が 0.78 となり, 全体の平均正答率は 0.57 となった. 「自分でも天体写真を撮る」人の平






図 5: アンケート結果

均正答率が高いものの、全体としてはすべてランダムに回答した場合のベースラインである 0.5 と同程度の結果となったため、一般的な人間の目を騙すことができる程度の画像が生成できていることがわかった。なお生成した星空画像の中で最も正答率が高かった画像は 7 番、最も正答率が低かった画像は 10 番であり正答率はそれぞれ 0.83 と 0.38 であった。このことから、人間の目からすると星雲や銀河があるほうがより星空写真らしく感じるということがわかった。

またアンケートでは、実験協力者がどこを見て生成した星空画像と星空写真を区別したのかという判断根拠についても調査した。その結果、「自分でも天体写真を撮る」人は銀河や星雲の形や色味に注目していることが多いが、そうでない人たちは全体の雰囲気や明るさに注目していることが多いことがわかった。この調査結果より、現状生成できている星空画像は全体の雰囲気や明るさに関しては実際の星空写真を再現できているといえる。一方で銀河や星雲の形や色といった細かい部分の再現はまだできていないことがわかったため、より銀河や星雲を含むデータを増やして実験をする必要があると考えられる。

### 3.2.2 識別実験

本実験では 3.1 で生成した星空画像と実際の星空写真を AI が見分けることができるのかという識別

表 2: 実験パラメータ (VGG19)


最適化関数	Adam
学習率	$1.0 \times 10^{-4}$
損失関数	Binary Cross Entropy
エポック数	20
画像サイズ	$128 \times 128$
バッチサイズ	6

実験をした。実験には VGG19 を使用し、ImageNet で学習済みのモデルをファインチューニングした。訓練データには、3.1 の方法で生成した 100 枚の星空画像、および Web スクレイピングによって収集してきた 100 枚の星空写真に、回転や切り抜きなどの Data Augmentation を施してそれぞれ 6000 枚、合計 12000 枚に拡張したものを使用した。またテスト画像には、3.1 の方法で生成した 10 枚の星空画像と大阪府立大学天文部より提供して頂いた 10 枚の星空写真を使用した。表 2 に実験パラメータを示す。初期重みには ImageNet で事前学習済みモデルを使用し、17 層目以降を転移学習した。表 3 に結果の混同行列を示す。表 3 の結果より、識別率が 0.95 と高いことから、人間の目では差がないように思われても AI からすれば生成した星空画像と実際の星空写真には明確な差があるということがわかった。

この原因が GAN による生成画像にあるのか、ま

表 3: 識別結果

		予測値	
		星空画像	星空写真
真値	星空画像	10	0
	星空写真	1	9



真値: 星空画像  
予測値: 星空画像

真値: 星空写真  
予測値: 星空写真

図 6: Grad-CAM の適用結果

たは星座の付加の方法にあるのかを確かめるために Grad-CAM を用いて CNN の注視領域を可視化した。図 6 に Grad-CAM の適用結果を示す。Grad-CAM の結果より、CNN は明るい星ではなく画像内の広い範囲を判断根拠にしていることがわかった。このことから、生成した星空画像と実際の星空写真との差は GAN による生成画像にあることがわかり、より実際の星空写真に類似した生成画像上に星座を付加することで AI を騙せるほどの高精度な画像を生成できるのではないかとこの考察が得られた。

### 3.3 星空画像の探索実験

本実験では、より星空写真と類似した画像を生成するために、GAN の Generator の潜在変数空間の中で実際の星空写真と類似した画像を生成する潜在変数を CMA-ES を用いて探索する手法を試みた。図 8 に潜在変数の探索手順を示す。図 8 における Generator と VGG19 はそれぞれ 3.1 で学習させた GAN の Generator と 3.2 で学習させた VGG19 であ

表 4: 識別結果 (探索終了後)

		予測値	
		星空画像	星空写真
真値	星空画像	7	3
	星空写真	0	10

る。そのため探索する潜在変数の次元数は 100 であり、これは CMA-ES における個体数に相当する。なお変数の探索範囲は  $[-1, 1]$  の間とし、探索にはパラメータ自動最適化ツールである Optuna が提供している CMA-ES の Sampler を使用した。

本実験では、探索した潜在変数を Generator に入力して得られた画像上に 3.1 で提案した方法と同じ方法で星座を付加し、生成された画像を VGG19 に入力した際の評価値を基に潜在変数を更新していく。このとき、各画像において VGG19 の出力の Softmax 値を調べ、星空写真のクラス出力値が大きくなるように CMA-ES を用いて潜在変数を更新した。また更新回数は 1000 回とし、これは CMA-ES における世代数に相当する。図 7 に探索の結果選択された画像例を示す。これらに星を付加した画像のうちの 50 枚と、3.2 で使用した訓練用画像のうちの 50 枚を合わせて訓練データに、同様にして探索によって生成した画像 5 枚と 3.2 で使用したテスト用画像のうちの 5 枚を合わせてテストデータとした。このようにデータを混ぜることで探索において同じような画像が選択された場合の影響を小さくすることを目的としている。

作成したデータセットを用いて再び識別実験をした。なお実験パラメータや実験条件は 3.2 と同じとした。表 4 に結果の混同行列を示す。

表 4 より、生成した星空画像を星空写真であると予測した率が上昇していることから、CMA-ES を用いることで CNN を騙せる画像が生成できたといえる。これより提案手法の有効性が示された。一方で誤識別率の上昇がわずかであったため今後は他の探索アルゴリズムの適用を検討していきたいと考えている。また、本研究では GAN の訓練に用いた元データ数が 200 枚と少なく同じような画像が生成される確率が高かったことも識別に影響を与えたと考えられるため、訓練データ数を増やすこともより実際の星空写真に類似した画像の生成に繋がると考えられる。




図 7: 探索の結果選択された画像例

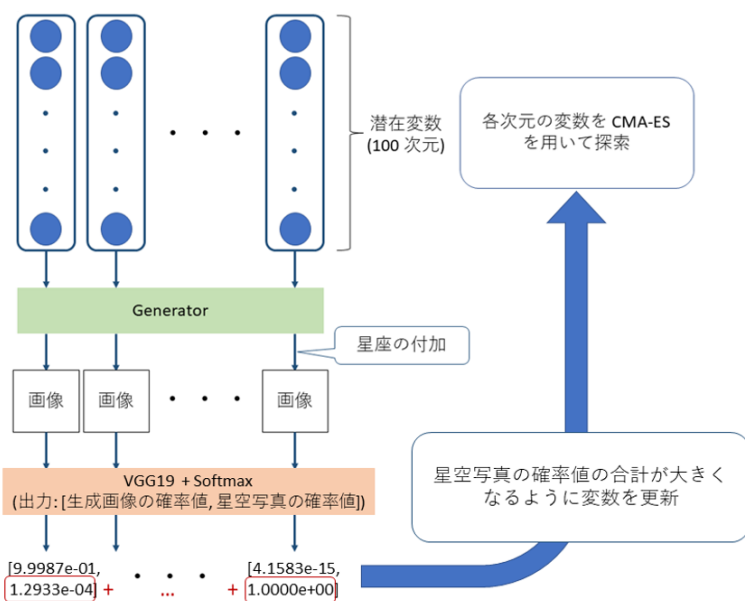


図 8: 潜在変数の探索手順

## 4 まとめと今後の課題

本研究では GAN とこれまでに提案した星図の作成方法を用いることで星空写真と類似した画像を生成する手法を提案し、アンケート調査を通して人間の目では実際の星空写真と類似していると思われる画像の生成に成功したことを確認した。またより星空写真と類似した画像を生成するために CMA-ES を用いた潜在変数の探索手法を提案し、その有効性を確かめた。一方で、まだ AI を完全に騙せるほどの精度の高い画像は生成できていないため、他の探索アルゴリズムを適用することや、訓練データ数を増やすことを検討し、最終目標として AI による星空

写真の自動編集システムの構築を目指す。

## 参考文献

- [1] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, and K. Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 27. Curran Associates, Inc., 2014.
- [2] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. *CoRR*, abs/1409.1556, 2015.
- [3] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, 128(2):336–359, Oct 2019.
- [4] N. Hansen and A. Ostermeier. Adapting arbitrary normal mutation distributions in evolution strategies: the covariance matrix adaptation. In *Proceedings of IEEE International Conference on Evolutionary Computation*, pages 312–317, 1996.
- [5] 灘本 紗也佳, 森 直樹, and 岡田 真. 星図データに基づく星座画像の生成と星座識別手法の提案. *人工知能学会全国大会論文集*, JSAI2021:3D1OS12a03–3D1OS12a03, 2021.